训练内部安全校准：20%风险线；门槛1.6时零覆盖
空接受集不等于判断准确，未根据验证/测试放松规则



